Map-Reduce

- 分布式系统
- 计算模型
- 调度与数据流
- 改进与优化

by @寒小阳

单节点结构

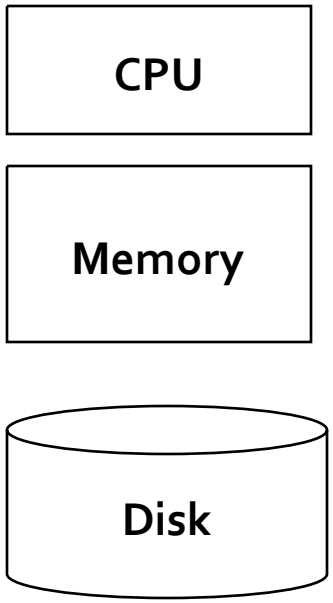

机器学习， 统计

“经典” 数据挖掘结构

动机：谷歌的例子

- 100亿个网页
- 平均网页大小 = 20KB
- 100亿 * 20KB = 200 TB
- 磁盘读取带宽 = 50 MB/sec
- 读取数据所需时间 = 400万秒 = 46+ 天
- 后续的数据处理与操作花费的时间可能会更多

集群的架构

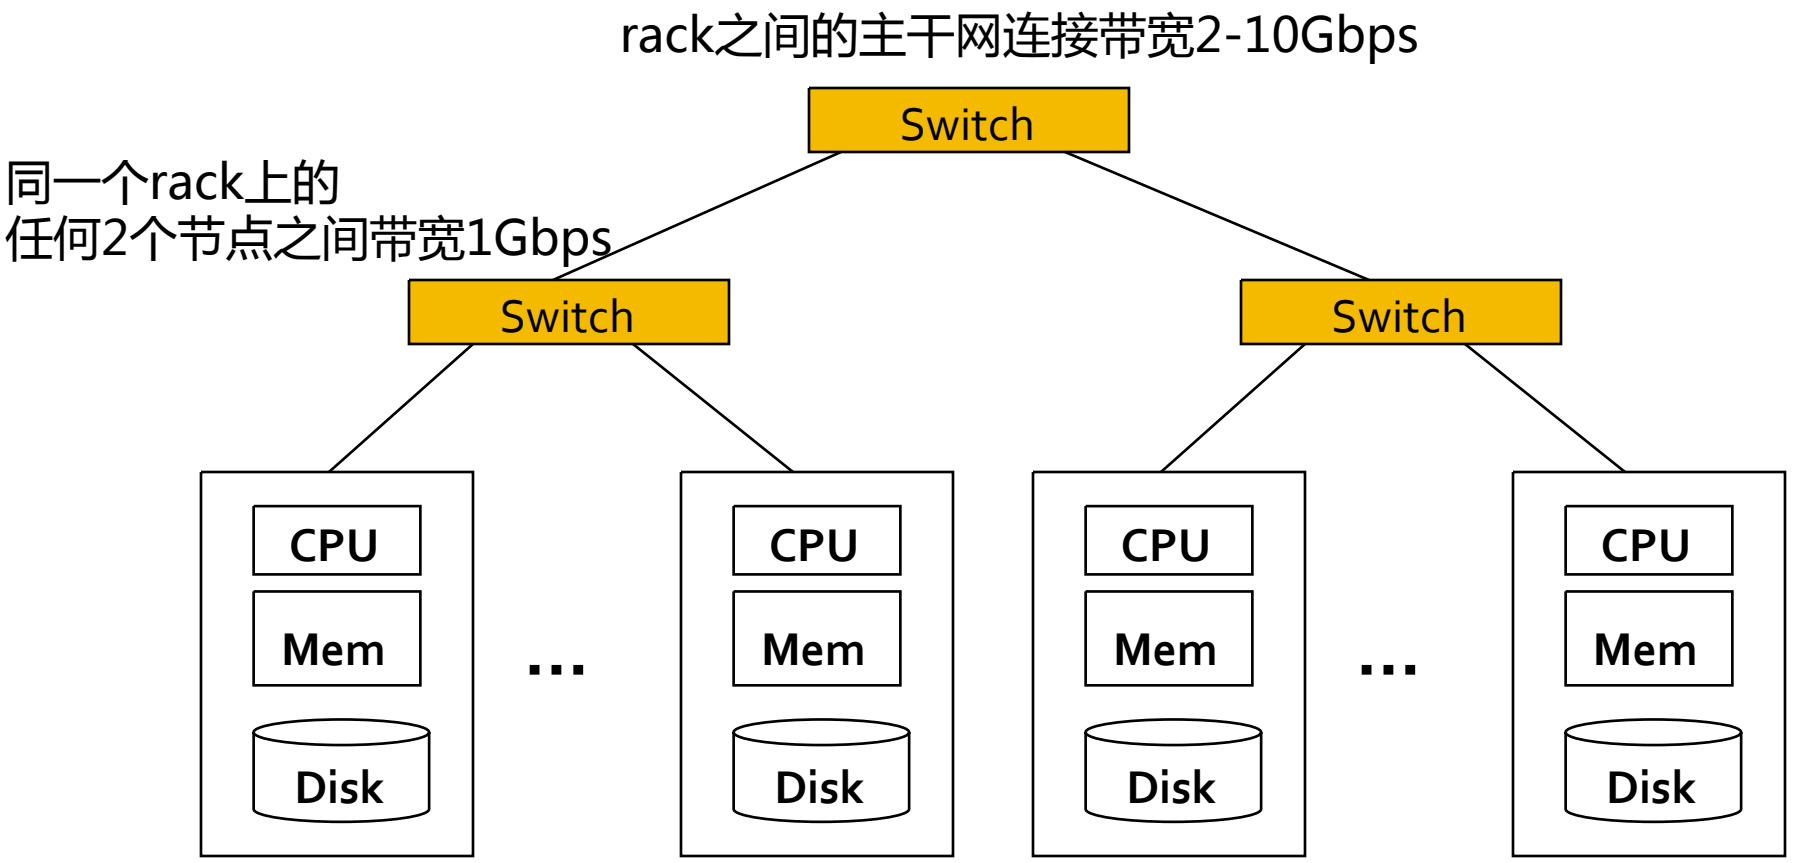

每一个rack 包含16到64个Linux 节点

2011年据统计，google约有100万台机器 ，详见 http://bit.ly/Shh0RO

集群计算需要面对的问题(1)

节点故障

- 单台服务器平均可以
- 1000台服务器的集群 => 平均故障率 1 次/天
- 100万台服务器的集群 => 平均故障率 1000 次/天

如何保持数据的持续性，
即在某些节点故障的情形下不影响依旧能够使用数据

在运行时间较长的集群运算中，如何应对节点故障呢

集群计算需要面对的问题(2)

网络带宽瓶颈

- 网络带宽 = 1 Gbps
- 移动10TB 数据需要花费将近一天

分布式编程非常复杂

- 需要一个简单的模型能够隐去所有的复杂性

Map-Reduce集群运算时问题的解决方案

- 在多节点上冗余地存储数据，以保证数据的持续性和一直可取性
- 将计算移向数据端，以最大程度减少数据移动
- 简单的程序模型隐藏所有的复杂度

冗余化数据存储结构

分布式文件存储系统

- 提供全局的文件命名空间，冗余度和可获取性
- 例如Google 的 GFS; Hadoop 的 HDFS

典型的应用场景与模式

- 超大级别的数据量(100GB到100TB级别)
- 数据很少就地整个被替换
- 最常见的操作为读取和追加数据

分布式文件系统

- 数据以“块状”形式在多台机器上存储
- 每个数据块都会重复地在多台机器上存储
- 保证数据的持续性和随时可取性

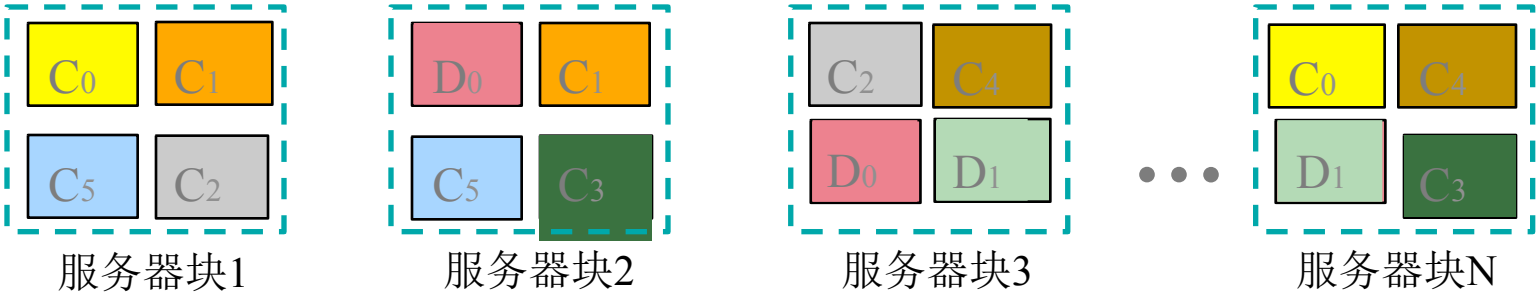

服务器块同时也用作计算服务器。

把运算挪向数据处！

分布式文件系统

服务器块

- 文件被分作16-64MB大小的连续块
- 每个文件块会被重复地存储2到3次
- 尽量保证重复的数据块在不同的机架上

主节点

- Hadoop的HDFS里叫做Name节点
- 存储元数据记录文件存储结构和地址
- 也可以重复

文件访问的客户端库

- 询问主节点以获取块服务器地址
- 直接连接相应服务器块获取数据

Map-Reduce

计算模型示例

编程模型：Map-Reduce

热身练习：

- 我们手头上有个超大的文本文件
- 我们需要统计每个文本中的词，所出现的次数
- 实际应用场景
  - 从web服务器日志中找出高频热门url
  - 搜索词统计

练习：词频统计

场景1:

- 文件本身太大无法全部载入内存
- 所有的词和频次对<word, count> 可以全部载入内存

练习：词频统计

场景2:

- 所有的词和频次对<word, count> 都超出了内存大小
- linux命令
  - **words(doc.txt) | sort | uniq -c**
    - 其中words命令输出一个文本内容中所有词，一个一行
- 场景2体现了MapReduce的精髓
  - 好事是它是纯天然并行化的

Map-Reduce：总览

```
words(doc.txt) | sort | uniq -c
```

Map

- 逐个文件逐行扫描
- 扫描的同时抽取出我们感兴趣的内容 (Keys)

Group by key

- 排序和洗牌

Reduce

- 聚合、总结、过滤或转换
- 写入结果

总体框架都和上述描述过程一致
只是Map和Reduce函数要根据具体问题具体实现

Map-Reduce： Map步骤

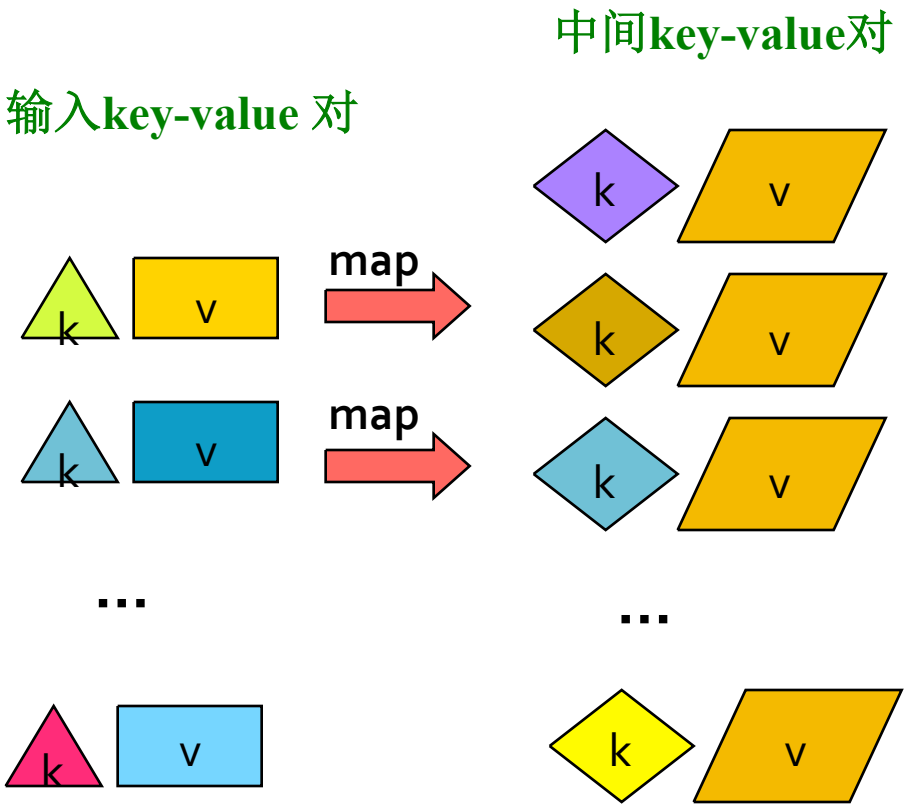

Map-Reduce： Reduce步骤

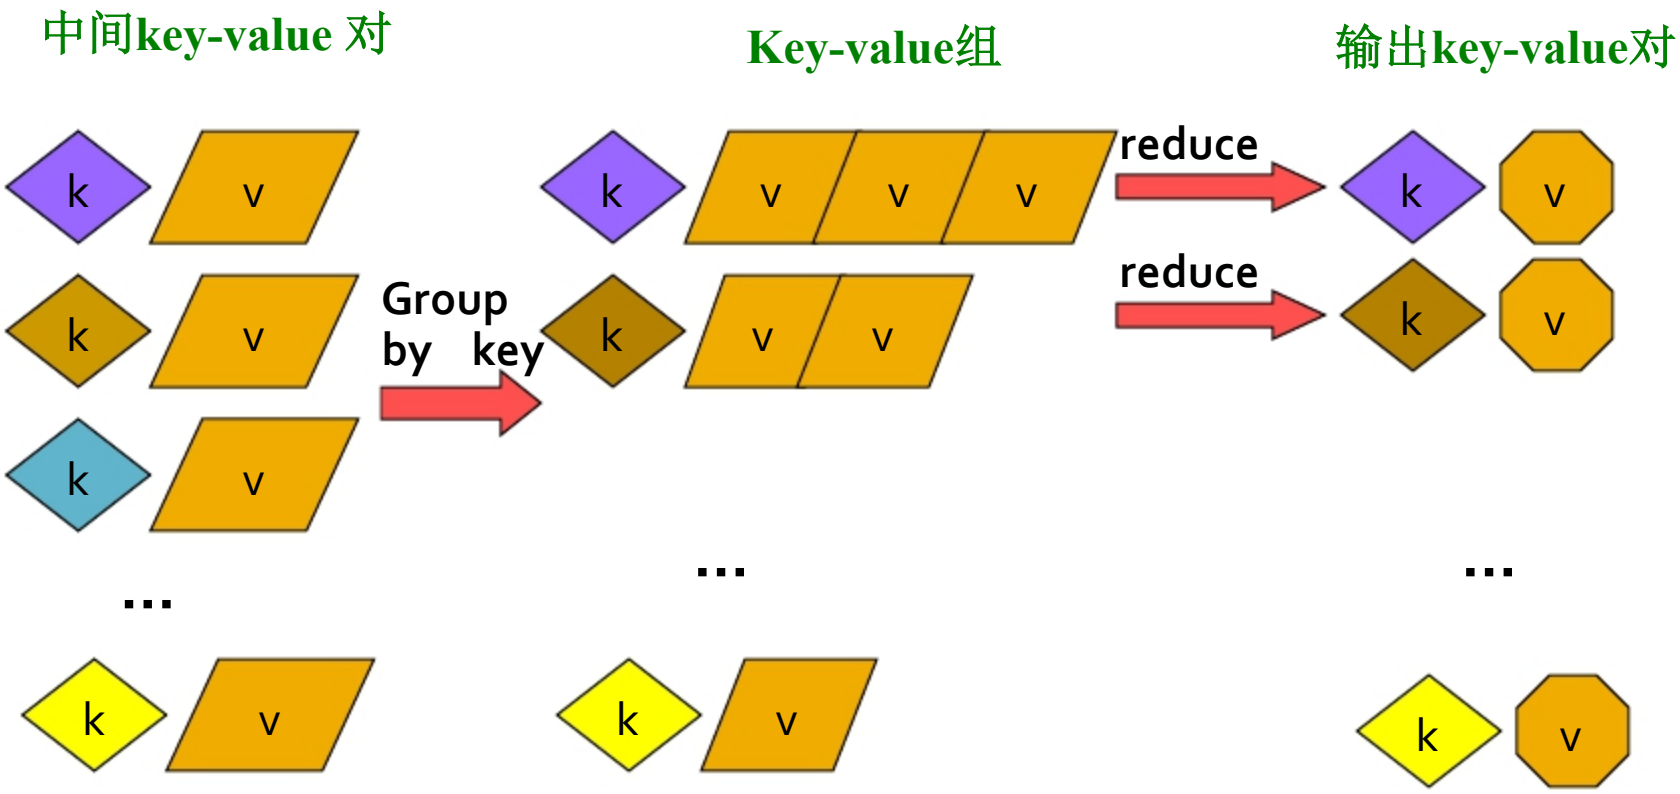

Map-Reduce步骤

输入： 一些键值对

- 编程人员需要定义两个函数:
  - **Map(k, v) → <k', v'>***
    - 对一个键值对输入产生一序列中间键值对
    - Map函数将对所有输入键值对操作
  - **Reduce(k', <v'>*) → <k', v''>***
    - 所有有相同key k' 的值v' 被reduce到一起
    - Reduce函数对每一个不同的Key k' 进行操作

Map-Reduce：词频统计

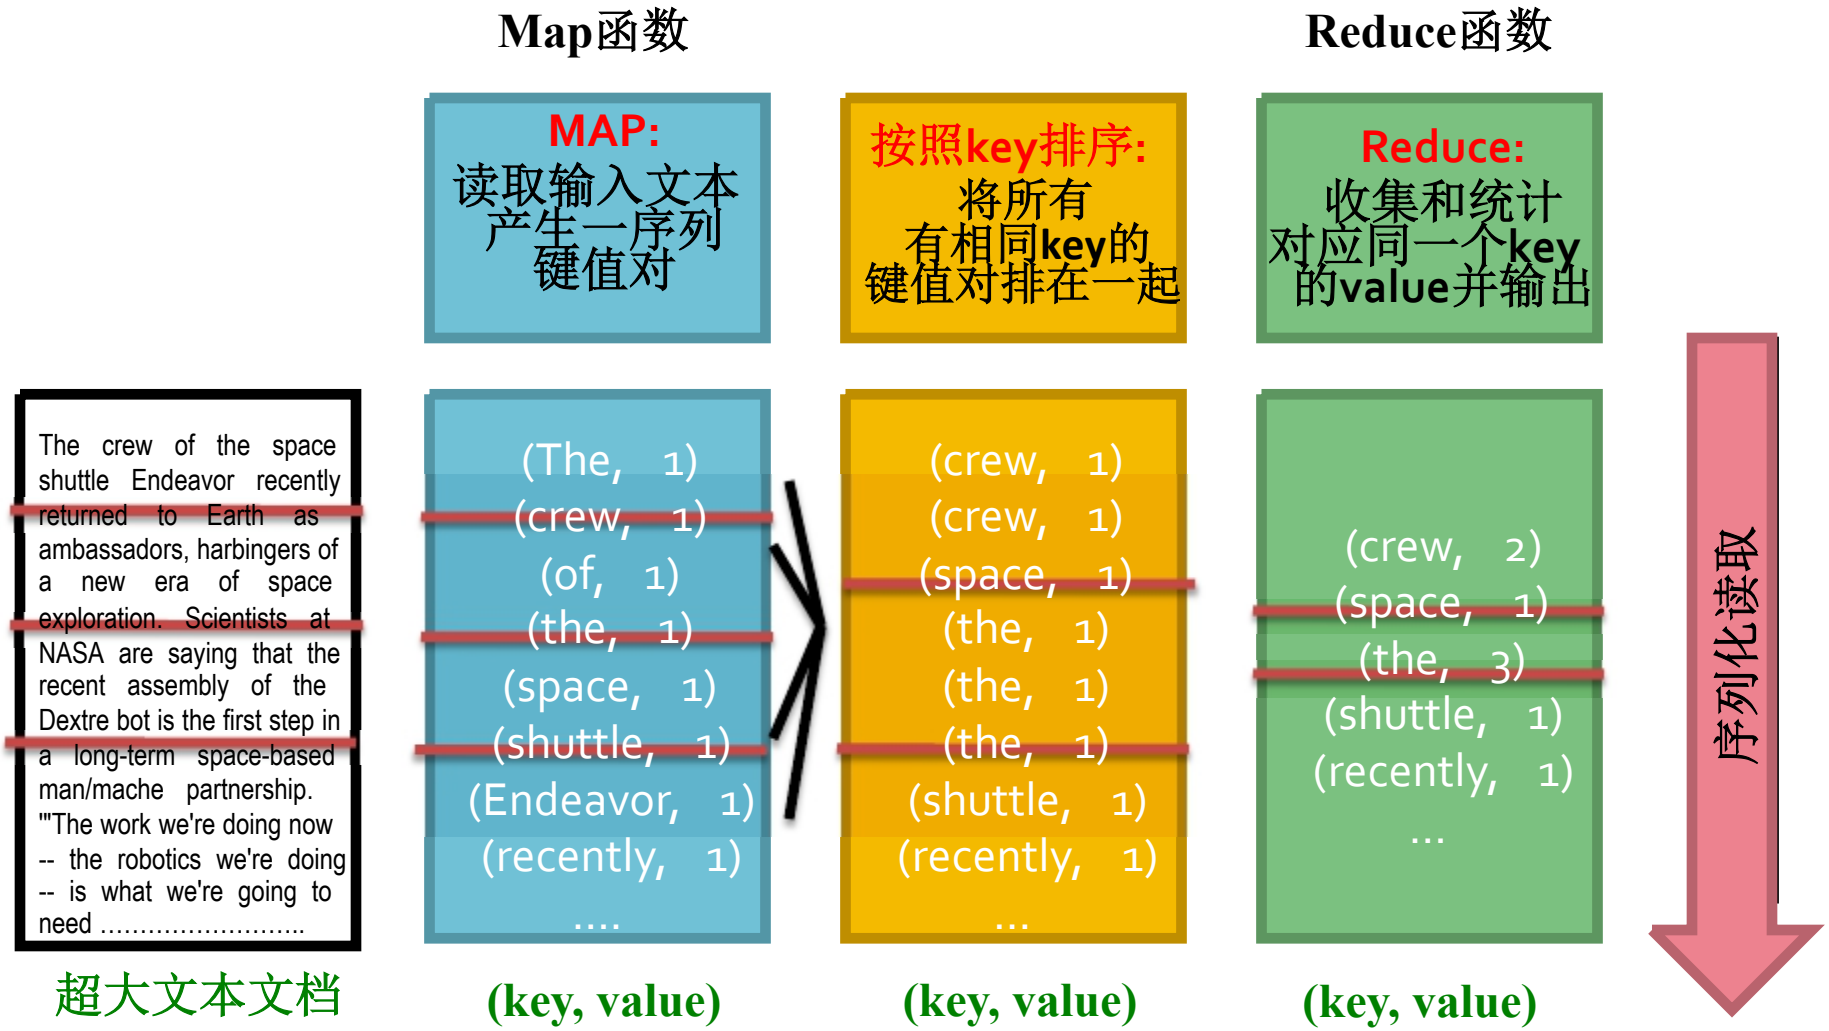

使用Map-Reduce统计词频

```
map(key, value):
// key: 文档名称;          value: 文档的文本内容
   for each word w in value:
      emit(w, 1)


reduce(key, values):
// key: 一个单词;          value: 一个计数的迭代器
      result = 0
      for each count v in values:
            result += v
      emit(key, result)
```

Map-Reduce示例2：Host大小

- 假设我们有一个大型网络语料库
  元数据文件格式如下
  - 每一条记录的格式都是：(URL，size, date, …)
- 对于每一个Host，获取其字节数(大小)

Map

- 顺序扫描，对每一条记录，生成键值对
  (hostname(URL)，size)

Reduce

- 对相同host的键值对的值(字节数)进行求和

Map-Reduce示例3：语言模型

- 即计算一个大型语料库中5词/字序列出现的次数

Map

- 顺序扫描，从原始语料库中生成键值对：

  (5-word sequence, count)

Reduce

- 对相同5词序列的计数(count)进行求和

Map-Reduce

调度与数据流

Map-Reduce示例图：

MAP:
读取输入文本
产生一序列
键值对

按照key排序:
将所有
有相同key的
键值对排在一起
(Hash merge, Shuffle, Sort, Partition)

Reduce:
收集和统计
对应同一个key
的value并输出

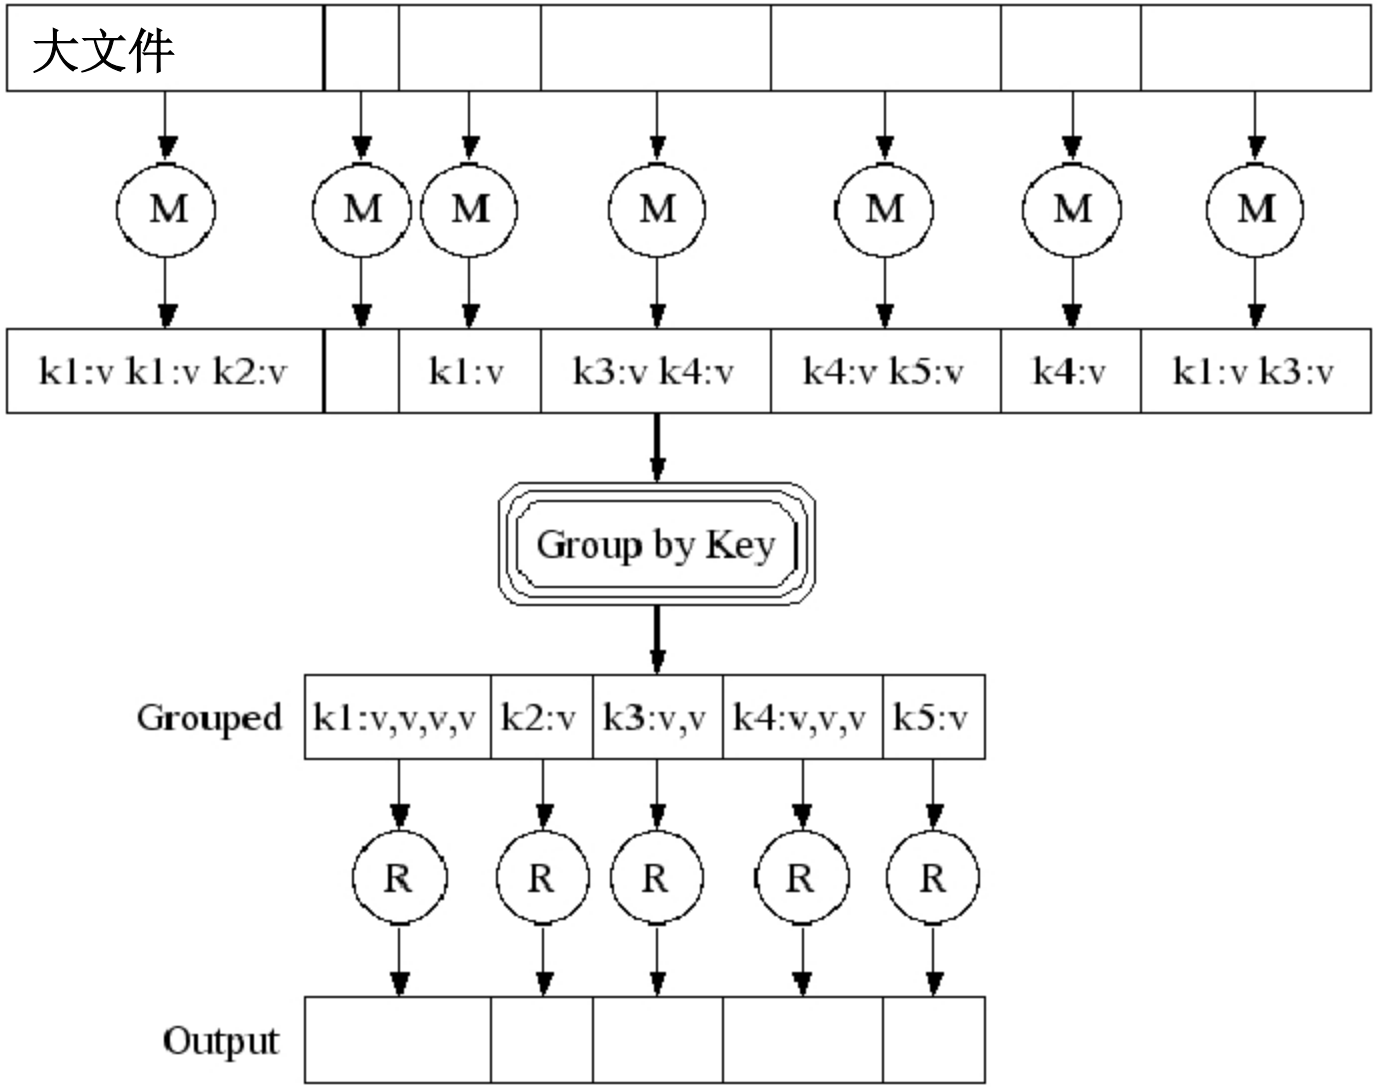

by @寒小阳

Map-Reduce：并行化

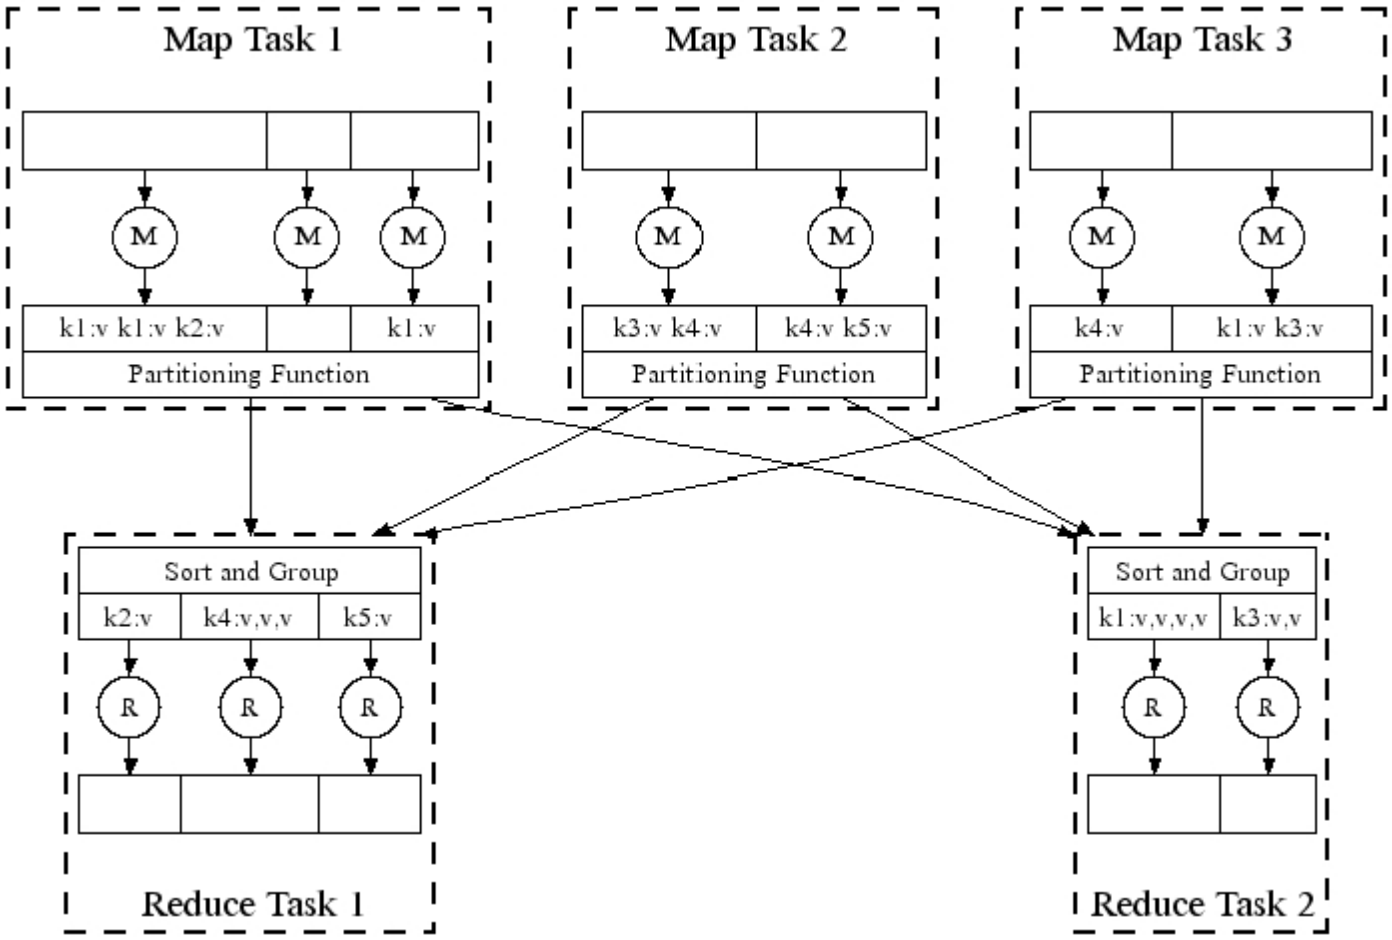

每一个阶段都有大量同类型的工作并行进行

by @寒小阳

Map-Reduce：环境

Map-Reduce 的背景环境需要负责:

- 对原始数据进行分区（partition）
- 调度程序在一系列的机器集群上都并行运行
- 执行中间过程的group by key步骤
- 处理运行过程中的突发节点故障
- 处理并行运行过程中的节点和节点之间的通信

数据流

- 输入和输出都被存储在分布式文件系统(DFS)上:
  - 实际调度操作时，调度器会尽可能将map任务移至靠近数据物理存储的节点上
  - 中间结果将会被存储在Map和Reduce操作的本地文件系统上
  - 实际运行过程中，**一个Map-Reduce产生的结果，很有可能作为另一个Map-Reduce任务的输入**

主节点的协调功能

主节点主要负责系统的协调

- 任务状态：等待初始，进行中，完成
- 一旦有能工作的worker，待初始任务被调度运行起来
- 一个Map任务完成后，它会向主节点发送它产生的R个中间文件的位置和大小，每个文件对应一个reducer
- 主节点将这些信息传送至reducer

处理节点故障

Map任务节点故障

- 所有运行中和已经完成的map任务，都被重置为待初始
- 所有这些待初始Map任务，将重新被分配到能工作的节点worker上。

Reduce任务节点故障

- 只有运行中而未完成的reduce任务被设定为待初始。
- 这些待初始reduce任务被重新分配至其他worker上。

11

主节点故障

- 整个Map-Reduce任务中断，同时通知客户端管理员。

启动多少个Map和Reduce任务呢？

- M个Map任务和R个Reduce任务
- 实际操作经验法则：
  - 通常情况下我们会让M远大于集群中的节点数
  - 通常设置为一个分布式文件系统块一个Map任务
  - 提升动态加载平衡，同时加速节点故障时的任务恢复
- 通常R比M要小
  - 因为输出要分布在R个文件上

Map-Reduce

改进与优化

改进：combiners(1)

- 很多时候一个Map任务为同一个key k会产生形如(k,v1), (k,v2)的键值对:
  - 例如，词频统计任务中的高频词产生的中间结果

- 我们通过在Mapper中，进行预聚合(pre-aggregating)操作，来节约网络的时间成本。
  - 合并　(k, list(v1)) → v2
  - 合并器(combiner)通常和reduce函数是一致的

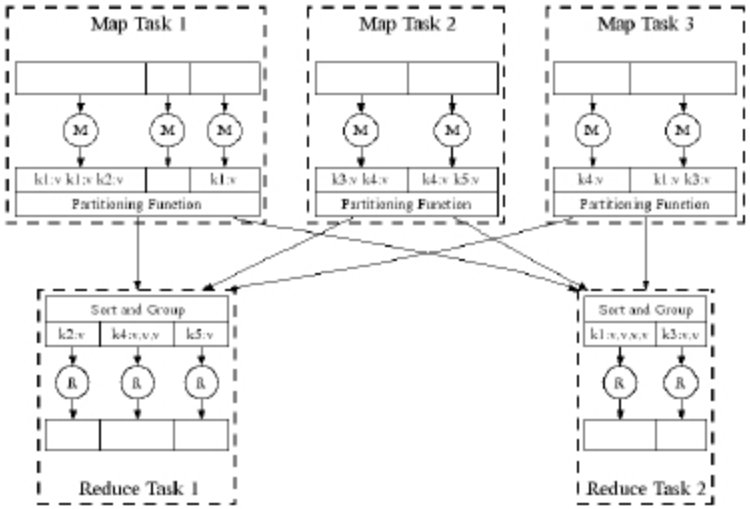

改进：combiners(2)

- 以词频统计为例:
  - 合并器(Combiner)预先合并了单个mapper(单个节点)中的键值对。

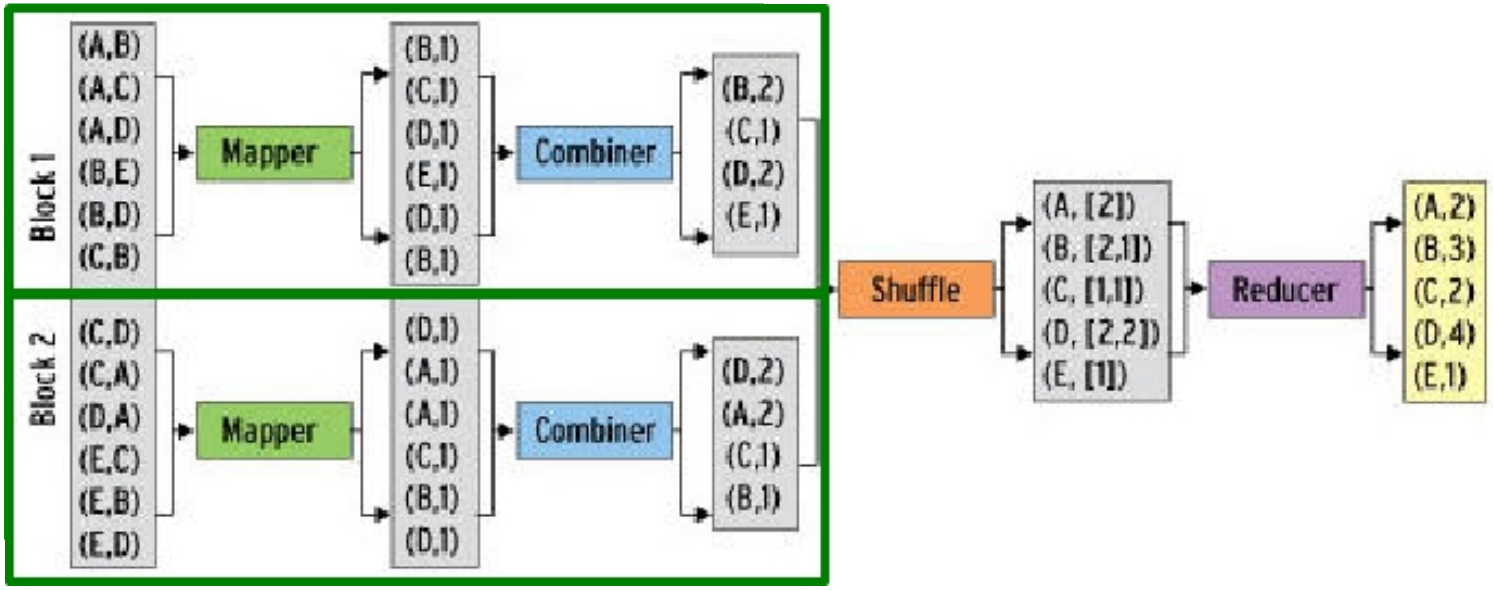

  - 优点：后续步骤只需要传输和重组更少的数据即可

改进：combiners(3)

- 注意:只有在满足交换律和结合律的条件下，combiner才能起作用
  - Sum（求和）
  - Average（求平均）
  - Median（求中间值）

改进：分区函数

- 控制键值对是如何分区/划分的
  - 保证指定key对应的键值对都分配到同一个reduce的worker中
- 系统有默认的分区函数
  - **hash(key) mod *R***
- 有时候自己指定划分分区的hash函数是很有用的
  - 例如，定义**hash(hostname(URL)) mod *R*** 可以确保所有同一个host的URL在同一个输出文件

Map-Reduce系统

- **Google MapReduce**
  - 使用google文件系统(GFS)用于稳定存储
  - google之外不开放使用
- **Hadoop**
  - 使用java实现的Map-Reduce开源框架
  - 使用HDFS进行稳定存储
  - 可以在http://lucene.apache.org/hadoop/下载使用
- **Hive，Pig**
  - 在Hadoop的Map-Reduce之上提供的类SQL数据提取操作功能

云计算

- 按小时计费的租赁计算系统
  - 可能会提供额外的服务：例如持续性存储

- 例如，亚马逊提供的“Elastic Compute Cloud” (EC2)
  - S3 (稳定性存储)
  - Elastic Map Reduce (EMR)

进一步阅读与相关资源

阅读

- Jeffrey Dean and Sanjay Ghemawat: MapReduce: Simplified Data Processing on Large Clusters
  - hbp://labs.google.com/papers/mapreduce.html
- Sanjay Ghemawat, Howard Gobioff, and Shun-Tak Leung: The Google File System
  - hbp://labs.google.com/papers/gfs.html

资源

- Hadoop Wiki
  - Introduction
  - http://wiki.apache.org/lucene-hadoop/
  - Geting Started
  - http://wiki.apache.org/lucene-hadoop/GettingStartedWithHadoop
  - Map/Reduce Overview
  - http://wiki.apache.org/lucene-hadoop/HadoopMapReduce
  - http://wiki.apache.org/lucene-hadoop/HadoopMapRedClasses
  - Eclipse Environment
  - http://wiki.apache.org/lucene-hadoop/EclipseEnvironment
- Javadoc
  - http://lucene.apache.org/hadoop/docs/api/

资源

- Releases from Apache download mirrors
  - http://www.apache.org/dyn/closer.cgi/lucene/hadoop
- Nightly builds of source
  - http://people.apache.org/dist/lucene/hadoop/nightly
- Source code from subversion
  - http://lucene.apache.org/hadoop/version_control.html