




凸集

如果一个集合C中的任意两点之间的线段也在该集合中，即集合C满足以下条件：

forall x1, x2 in C, theta in R, 0 <= theta <= 1  
theta x1 + (1 - theta) x2 in C

那么集合C可以称为凸集.



推广至一般情况，对于参数theta的不同约束可得到


名称	约束
凸集	sum_i^n theta_i = 1, theta_i >= 0
仿射集	sum_i^n theta_i = 1
凸锥	forall theta_i >= 0

凸函数

如果函数f: R^n -> R满足以下条件：

forall x1, x2 in dom(f), theta in R, 0 <= theta <= 1  
f(theta x1 + (1 - theta) x2) <= theta f(x1) + (1 - theta) f(x2)

其中，dom(f)是凸集，那么函数f是一个凸函数.



严格凸 | 当x1 != x2, 0 < theta < 1.

凹函数 | 当-f是一个凸函数.


严格凹 | 当-f是一个严格凸函数.

推广至多个数据点，sum\_i^n theta\_i = 1, theta\_i >= 0

f(sum\_{i=1}^n theta\_i x\_i) <= sum\_{i=1}^n theta\_i f(x\_i).

即f(E[x]) <= E[f(x)], 称为Jensen不等式.

凸函数的几何意义




判断函数凸性的方式 ✓ 一阶条件 ✓ 二阶条件

一阶条件 | 如果一个函数f: R^n -> R在dom(f)上处处可导，满足以下条件：

forall x1, x2 in dom(f)  
f(x2) >= f(x1) + grad f(x1)^T (x2 - x1)

则f为凸函数



二阶条件 | 如果一个函数f: R^n -> R在dom(f)上的所有点二阶导数存在，并满足以下条件：

forall x in dom(f) grad^2 f(x) >= 0

即如果f的Hessian矩阵为半正定矩阵，那么f为凸函数.

优化问题

标准形式 | 给定x in R^n，在满足条件fi(x) <= 0以及hi(x) = 0的所有x中寻找极小化f0(x)的取值，即

min\_x f0(x) | 目标函数 R^n -> R  
s.t. fi(x) <= 0, i = 1, ..., m | 不等式约束 R^n -> R  
hi(x) = 0, i = 1, ..., p | 等式约束 R^n -> R

当m = p = 0，该问题称为无约束问题

如果问题定义域中的x满足约束条件，那么x是可行的；所有可行点的集合称为可行集

最优值 | 满足以下条件的p\* in [-inf, inf]：

p\* = inf{f0(x) | fi(x) <= 0, hi(x) = 0}

✓ 如果问题不可行，则p\* = inf

✓ 如果xk为可行解，满足k -> inf, f0(x + k) -> -inf

则p\* = -inf，该优化问题无下界

最优点 | 最优点x\*是可行解，且f0(x\*) = p\*

局部最优 | 可行解x为局部最优解，如果存在R > 0，使得以下条件成立

f0(x) = inf{f0(y) | fi(y) <= 0, i = 1, ..., m,  
hi(y) = 0, i = 1, ..., p, ||y - x||2 <= R}

松弛变量 | 引入s in R^m，将不等式约束替换为等式约束，原优化问题可以表示为

min\_x f0(x)  
s.t. si >= 0, i = 1, ..., m  
fi(x) + si = 0, i = 1, ..., m  
hi(x) = 0, i = 1, ..., p

常见凸优化问题的数学描述

线性规划	二次规划	二次约束二次规划	半定规划
$G \in \mathbb{R}^{m \times n}, A \in \mathbb{R}^{p \times n}$	$G \in \mathbb{R}^{m \times n} A \in \mathbb{R}^{p \times n}, P \in \mathbb{R}_{+}^n$	$P_i \in \mathbb{S}_{+}^n, i = 1, \dots, m$	$C, A_1, \dots, A_p \in \mathbb{S}^n$
$\begin{aligned} \min_x \quad & c^T x + d \\ \text{s.t.} \quad & Gx \preceq h \\ & Ax = b \end{aligned}$	$\begin{aligned} \min_x \quad & \frac{1}{2} x^T P x + q^T x + r \\ \text{s.t.} \quad & Gx \preceq h \\ & Ax = b \end{aligned}$	$\begin{aligned} \min_x \quad & \frac{1}{2} x^T P_0 x + q_0^T x + r_0 \\ \text{s.t.} \quad & Ax = b \\ & \frac{1}{2} x^T P_i x + q_i^T x + r_i \leq 0 \end{aligned}$	$\begin{aligned} \min_x \quad & \text{Tr}(CX) \\ \text{s.t.} \quad & \text{Tr}(A_i X) = b_i \\ & X \succeq 0 \end{aligned}$

凸优化问题

凸优化问题 | 形如以下格式的优化问题

min\_x f0(x)  
s.t. fi(x) <= 0, i = 1, ..., m  
ai^T x = bi, i = 1, ..., p

其中，f0, ..., fm均为凸函数

凸优化问题的特点 | 满足以下条件：

✓ 目标函必须是凸函数

✓ 不等式约束函数必须是凸函数

✓ 等式约束约束函数必须是放射函数

✓ 局部最优解和全局最优解等价

如果目标函数可微，根据凸函数的定义，有

forall x, y in dom(f)  
f(y) >= f(x) + grad f(x)^T (y - x)


凸优化问题的可行集X可表示为

X = {x | fi(x) <= 0, hi = 0}

最优解 | x为最优解，当且仅当满下条件

{ x in X  
f(y) >= f(x) + grad f(x)^T (y - x)

f0(x)最优性条件的几何意义



常见的凸优化问题形式：

线性规划 | 仿射目标函数和约束函数.

二次规划 | 二次型目标函数和仿射约束函数.

二次约束二次规划 | 二次型目标、约束函数.

半定规划 | n维对称矩阵.







## 对偶

**Lagrange函数** | 获取优化问题约束条件的加权和，放入原有目标函数，得到增广的目标函数

$$\mathcal{L} : \mathbb{R}^n \times \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}$$

$$\mathcal{L}(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)$$


其中， $\lambda_i, v_i$ 为对应的Lagrange乘子

**Lagrange对偶函数** | 对于 $\lambda \in \mathbb{R}^m, v \in \mathbb{R}^p$ ，Lagrange函数有关 $x$ 可以取得的最小值

$$g : \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}$$

$$g(\lambda, v) = \inf_x \left( f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x) \right)$$

**最优值下界** | Lagrange对偶函数为原始优化问题最优值 $p^*$ 的下界，即  $\forall \lambda \succeq 0, \lambda, g(\lambda, v) \leq p^*$



**共轭函数** | 给定函数 $f : \mathbb{R}^n \rightarrow \mathbb{R}$ ，共轭函数 $f^*$ 为

$$f^*(y) = \sup_x \left( y^T x - f(x) \right)$$

**Lagrange函数和共轭函数的联系** | 给定具有等式约束的优化问题  $\min_x f(x) \quad \text{s.t. } x = 0$

✓ 该问题的Lagrange函数为 $\mathcal{L} = f(x) + v^T x$

✓ Lagrange函数的对偶函数为

$$g(v) = \inf_x \left( f(x) + v^T x \right) = -\sup_x \left( -f(x) + (-v)^T \right) = -f^*(-v)$$

**Lagrange对偶问题** | 原问题最优值 $p^*$ 的下界，与 $\lambda, v$ 相关，可以描述为一个新的优化问题

$$\max_{\lambda, v} g(\lambda, v) \quad \text{s.t. } \lambda \succeq 0$$

由于目标函数为凹函数，约束集合为凸集，对偶问题仍是凸优化问题；对偶问题的凸性和原问题无关；如果 $(\lambda^*, v^*)$ 为对偶问题的最优解，那么 $(\lambda^*, v^*)$ 称为**最优Lagrange乘子**。

**弱对偶性** | 如果 $d^*$ 表示Lagrange对偶问题的最优取值，那么不等式  $d^* \leq q^*$ ；即使原问题不是凸优化问题，该不等式依然成立。

**最优对偶间隙** |  $p^* - d^*$

如果原问题很难求解，那么基于弱对偶性，可以将求解原问题转化为求解其对偶问题

**强对偶性** | 等式 $d^* = p^*$ 成立，即最优对偶间隙为零；一般情况下，强对偶性不成立；如果原问题是一个凸问题，强对偶性通常成立

## Lagrange对偶的鞍点解释

**对偶性的极大极小描述** | 假设优化问题没有等式约束，可以有

$$\begin{aligned} \sup_{\lambda \succeq 0} \mathcal{L}(\lambda, x) &= \sup_{\lambda \succeq 0} \left( f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) \right) \\ &= \begin{cases} f_0(x) & f_i(x) \leq 0, i = 1, \dots, m \\ \infty & \text{其他} \end{cases} \end{aligned}$$

基于上式，原问题的最优值可以表示为

$$p^* = \inf_x \sup_{\lambda \succeq 0} \mathcal{L}(x, \lambda)$$

同样地，对偶问题则可以表示为

$$d^* = \sup_{\lambda \succeq 0} \inf_x \mathcal{L}(x, \lambda)$$

**弱对偶性**可以使用下列不等式表示

$$\sup_{\lambda \succeq 0} \inf_x \mathcal{L}(x, \lambda) \leq \inf_x \sup_{\lambda \succeq 0} \mathcal{L}(x, \lambda)$$

**强对偶性**可以使用下列等式表示

$$\sup_{\lambda \succeq 0} \inf_x \mathcal{L}(x, \lambda) = \inf_x \sup_{\lambda \succeq 0} \mathcal{L}(x, \lambda)$$

**极大极小不等式** |  $\forall f : \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}$ ，以下不等式成立，且  $W \subseteq \mathbb{R}^n, Z \subseteq \mathbb{R}^m$

$$\sup_{z \in Z} \inf_{w \in W} f(w, z) \leq \inf_{w \in W} \sup_{z \in Z} f(w, z)$$

如果等式成立， $f$ 则满足**鞍点**性质

**鞍点** |  $\forall w \in W, z \in Z$ ，下列不等式成立

$$f(\tilde{w}, z) \leq f(\tilde{w}, \tilde{z}) \leq f(w, \tilde{z})$$

$(\tilde{w}, \tilde{z})$ 称为函数 $f$ 的**鞍点**；如果 $x^*$ 为原问题的最优值点， $\lambda^*$ 为对偶问题的最优点，且强对偶性成立，那么 $(x^*, \lambda^*)$ 为Lagrange函数的鞍点。

## 最优性条件

**互补松弛性** | 若优化问题的强对偶性成立，给定 $x^*$ 、 $(\lambda^*, v^*)$ 为原问题和对偶问题的最优解，有

$$\begin{aligned} f_0(x^*) &= g(\lambda^*, v^*) \\ &= \inf_x \left( f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{i=1}^p v_i^* h_i(x) \right) \\ &= f_0(x^*) + \sum_{i=1}^m \lambda_i^* f_i(x^*) + \sum_{i=1}^p v_i^* h_i(x^*) \\ &\leq f_0(x^*) \end{aligned}$$

从上式可以得知 $\sum_{i=1}^m \lambda_i^* f_i(x^*) = 0$ ，即 $\lambda_i^* f_i(x^*) = 0$  互补松弛条件可以表示为

$$\begin{cases} \lambda^* > 0 \implies f_i(x^*) = 0 & \text{或者} \\ \lambda^* < 0 \implies f_i(x^*) = 0 \end{cases}$$

**KKT条件** | 若优化问题的目标函数和约束函数可微，对偶间隙为零。那么， $\mathbb{L}(x, \lambda^*, v^*)$ 在 $x = x^*$ 处取得最小值，则有

$$\nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{i=1}^p v_i^* \nabla h_i(x^*) = 0$$

因此，列出优化问题的**KKT条件**

$$\begin{cases} f_i(x) \leq 0, i = 1, \dots, m \\ h_i(x^*) = 0, i = 1, \dots, p \\ \lambda_i^* \geq 0, i = 1, \dots, m \\ \lambda_i^* f_i(x^*) = 0, i = 1, \dots, m \\ \nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{i=1}^p v_i^* \nabla h_i(x^*) = 0 \end{cases}$$

**凸问题的KKT条件** | 如果原问题为凸问题，满足KKT条件的点也是原问题和对偶问题的最优解。

**Slater条件** |  $\exists \in \text{relint} \mathcal{D}$ ，使得下式成立

$$f_i(x) < 0, i = 1, \dots, m \quad Ax = b$$

其中 $\mathcal{D}$ 为目标函数定义域， $\text{relint} \mathcal{D}$ 为定义域的相对内部。  
当Slater条件成立且原问题为凸问题时，强对偶性成立  
✓ 如果凸优化问题的目标函数和约束函数可微，且满足Slater条件，那么KKT条件为该问题最优性的**充要条件**  
✓ 在实际的情形下，求解凸问题的方法可以转换为求解其KKT条件的方法。

## 凸优化算法概要

**无约束优化** | 优化问题的目标函数 $f : \mathbb{R}^n \rightarrow \mathbb{R}$ 二次可微，最优点满足充要条件

$$\nabla f(x^* = 0)$$

通过计算上述方程的解，得到优化问题的最优解；实际情形中，使用**迭代算法**获得最优解，计算数列 $x^0, x^1, \dots, x^k$ ，使得 $k \rightarrow \infty$ ， $f(x^k) \rightarrow p^*$   
**下降方法** | 该方法产生一个数列 $\{x^k\} k = 1, \dots$ ，满足以下的等式

$$x^{k+1} = x^k + t^k \Delta x^k$$

其中， $\Delta x$ 表示**搜索方向**； $t^k$ 表示第 $k$ 次迭代的**步长**；下降方法的搜索方向必须满足

$$\nabla f(x^k)^T \Delta x^k < 0$$

**下降方法算法框架** | 重复以下步骤，直至满足终止条件

- ✓ 确定搜索方向 $\Delta x$
- ✓ 使用合适的搜索方法确定步长 $t > 0$
- ✓ 更新 $x, x := x + t \Delta x$

**梯度下降法** | 负梯度为搜索方向  $\Delta x = -\nabla f(x)$

**Newton法** | Newton法的搜索方向：

$$\Delta x_{Newton} = -\nabla^2 f(x)^{-1} \nabla f(x)$$

**等式约束优化** | 优化问题的目标函数 $f : \mathbb{R}^n \rightarrow \mathbb{R}$ 为二次连续可微凸函数，最优点满足充要条件

$$Ax^* = b, A \in \mathbb{R}^{p \times n}, \nabla f(x^*) + A^T v^* = 0$$

等式约束优化问题可以通过以下两种方式求解：

- ✓ 消除等式约束转化为等价的无约束优化问题
- ✓ 求解对偶问题，从对偶解中复原原问题最优解

**Newton法** | 假设KTT矩阵非奇异，确定Newton方向

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} \Delta x_{newton} \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$$

其中， $w$ 为优化问题的最优对偶变量

**内点法** | 使用内点法求解不等式约束问题，实质是使用Newtorn法求解一系列等式约束问题

**障碍法** | 顺序求解一系列等式约束或者无约束优化问题，每次使用获取的最新点作为求解下一个优化问题的起始点，该方法称为序列无语色输极小化技术，也称为**障碍方法**，或者**路径跟踪法**。

